

Acta de Constitución del Proyecto

Caso de estudio simulado: Predicción de bloques de alta demanda de seguridad ciudadana para priorización de patrullaje preventivo en Quito

1. Información del equipo

Nombre del equipo: DataSafe Quito
Dominio asignado: Seguridad Ciudadana
Fecha de constitución: 05/06/2026
Link al repositorio: [colocar link de GitHub/GitLab]

El equipo estará conformado por cinco integrantes. La documentación, presentación final y gestión del avance serán responsabilidades compartidas por todos los miembros del grupo.

Integrante	Rol asignado	Responsabilidad principal
Juan Sebastián Andrade	ML Engineer	Diseñar el flujo de entrenamiento, validación, métricas, reproducibilidad y preparación del modelo para evaluación
Nathaly Villenas	Data Engineer	Generar la data sintética, estructurar el dataset, validar calidad inicial y construir el pipeline de datos
Gabriel Piedra	Data Analyst	Realizar análisis exploratorio de datos, visualizaciones, identificación de patrones e interpretación inicial
David Escobar	Data Scientist	Formular el enfoque analítico, probar modelos predictivos, comparar resultados y explicar variables relevantes
Matías Puente	Data Governance / DPO	Revisar privacidad, cumplimiento de la LOPDP, riesgos de tratamiento de datos y lineamientos de uso responsable

2. Definición del problema

La seguridad ciudadana es una preocupación importante en zonas urbanas, especialmente cuando los recursos de patrullaje, monitoreo y respuesta son limitados. En muchos casos, las autoridades deben decidir dónde ubicar personal de seguridad, en qué horarios reforzar la vigilancia y qué sectores requieren atención prioritaria.

El problema de negocio consiste en que la toma de decisiones sobre patrullaje preventivo muchas veces se realiza de forma reactiva, es decir, después de que los incidentes ya ocurrieron. Esto puede generar demoras en la respuesta, mala distribución de recursos y menor percepción de seguridad en la ciudadanía.

Este proyecto busca apoyar a una Dirección de Seguridad Ciudadana ficticia del Municipio de Quito mediante un modelo analítico que permita identificar patrones de riesgo según variables como tipo de incidente, administración zonal, franja horaria, día de la semana, mes y feriados. El objetivo no es reemplazar la decisión humana, sino entregar una herramienta de apoyo para priorizar zonas y horarios con mayor probabilidad de incidentes.

Stakeholder principal: Director/a de Seguridad Ciudadana del Municipio de Quito.

Usuarios secundarios: equipo de análisis de datos, coordinadores de patrullaje, operadores de monitoreo y autoridades locales.

Análisis breve del contexto tipo PESTEL

Político: La seguridad ciudadana es una prioridad para gobiernos locales y nacionales, por lo que existe interés en herramientas que permitan asignar mejor los recursos públicos.

Económico: Los recursos para patrullaje, cámaras, vehículos y personal son limitados. Un modelo predictivo puede ayudar a usar estos recursos de forma más eficiente.

Social: La percepción de inseguridad afecta la movilidad, el comercio, la vida comunitaria y la confianza en las instituciones.

Tecnológico: Existen herramientas de análisis de datos, sistemas de información geográfica y modelos predictivos que pueden apoyar la planificación preventiva.

Legal: El uso de datos debe respetar la Ley Orgánica de Protección de Datos Personales de Ecuador. El proyecto utilizará datos ficticios y, en caso de simular

datos reales, se considerará consentimiento, anonimización, minimización de datos y finalidad específica.

Ambiental: Factores como clima, temperatura, horarios nocturnos o eventos masivos pueden influir en la ocurrencia o reporte de incidentes.

3. Pregunta analítica

¿Qué combinación de administración zonal, franja horaria, día de la semana, mes, feriado y tipo de incidente permite predecir si un bloque zona-hora tendrá alta demanda de seguridad ciudadana, para priorizar patrullaje preventivo con un F1-score mínimo de 0.75 y recall mínimo de 0.80 para la clase “alta demanda”?

De forma más simple, el proyecto busca responder:

¿En qué zonas, días y horarios se espera mayor demanda de atención de seguridad ciudadana para distribuir mejor los recursos de patrullaje preventivo?

4. Criterios/Métricas de éxito

Tipo	Métrica	Criterio
Técnica	F1-score clase alta demanda	≥ 0.75
Técnica complementaria	Recall clase alta demanda	≥ 0.80
Negocio	Cobertura operativa en bloques priorizados	Capturar $\geq 65\%$ de bloques de alta demanda priorizando máximo 30% de bloques

5. Descripción de datos

El proyecto trabajará con un dataset ficticio generado en Python usando librerías como Faker, NumPy y pandas. Se generarán aproximadamente **5.000 registros simulados** de incidentes de seguridad ciudadana en zonas urbanas.

5.1 Variables propuestas y comportamiento esperado

Variable	Descripción	Tipo de dato	Comportamiento esperado para simulación	Nivel de sensibilidad LOPDP	Justificación
id_registro	Identificador único del registro sintético	Numérica / identificador	Secuencial, sin relación con personas reales	Bajo	No identifica a una persona natural. Solo sirve para control interno del dataset.
fecha	Fecha del bloque de observación	Fecha	Distribución durante un año calendario. Puede simularse de forma uniforme, pero con variaciones por mes.	Bajo	No es sensible por sí sola, siempre que no esté asociada a una persona identificable.

mes	Mes del año derivado de la fecha	Numérica / categórica	Variable categórica con posibles variaciones estacionales. No debe asumirse uniforme si se busca mayor realismo.	Bajo	Es una variable temporal agregada.
día_semana	Día de la semana derivado de la fecha	Categórica	Distribución categórica. Puede tener mayor peso en viernes, sábado o domingo según el tipo de incidente.	Bajo	Es una variable temporal agregada.
hora	Hora del día del bloque de observación	Numérica discreta	Variable cíclica de 0 a 23. Puede tener mayor concentración en madrugada, tarde o noche según el tipo de incidente.	Bajo a medio	Por sí sola no identifica a una persona, pero combinada con ubicación exacta podría aumentar el riesgo.
franja_horaria	Agrupación de horas: madrugada	Categórica	Se deriva de la hora. Reduce granularidad y	Bajo	Es más segura que usar

	a, mañana, tarde, noche		ayuda a proteger privacidad.		hora exacta.
es_feriado	Indica si la fecha correspon de a feriado	Binaria	Variable 0/1. Puede aumentar ligeramente la intensidad esperada de ciertos incidentes.	Bajo	No identifica personas. Es una variable contextual .
administración_ zonal	Zona administrat iva del Distrito Metropolita no de Quito	Categóric a	Distribución no uniforme. Algunas administracio nes zonales pueden concentrar más registros que otras.	Medio	No identifica directame nte a personas, pero represent a ubicación territorial. Debe evitarse llegar a direccione s exactas.
tipo_incidente	Categoría del incidente reportado o simulado	Categóric a	Distribución multinomial desbalancead a. Algunos incidentes serán más frecuentes que otros.	Medio	Puede afectar la percepció n de seguridad de una zona. Debe usarse de

					forma agregada y responsable.
conteo_incidentes	Número de incidentes simulados en un bloque zona-hora	Numérica discreta	Distribución de conteo. Se puede simular con Poisson usando una intensidad ajustada por zona, hora, día y tipo de incidente.	Medio	No contiene personas, pero representa eventos de seguridad. Debe evitarse exponer datos demasiados o específicos.
alta_demanda	Variable objetivo que indica si un bloque tiene alta demanda operativa	Binaria	Se puede definir con percentil 75 del conteo de incidentes. 1 = alta demanda, 0 = demanda normal.	Medio	Es una etiqueta analítica creada por el equipo. Puede influir en decisiones de patrullaje, por lo que debe ser explicable.

5.2 Nivel de sensibilidad de datos

El dataset utilizado en este proyecto será sintético, por lo que no contendrá nombres, cédulas, teléfonos, direcciones exactas, placas de vehículos, coordenadas precisas ni información de víctimas o denunciantes reales. Por esta razón, el dataset académico tiene un nivel de sensibilidad bajo.

Sin embargo, el caso de uso simulado representa un contexto real de seguridad ciudadana. En un escenario operativo, este tipo de información podría alcanzar un nivel de sensibilidad medio-alto, especialmente si se combinan variables como hora exacta, ubicación específica, tipo de incidente y frecuencia de reportes. Aunque estos datos no necesariamente sean sensibles por sí solos, su combinación podría generar riesgos de perfilamiento territorial, estigmatización de zonas o exposición de patrones operativos de seguridad.

Por ello, el proyecto aplicará principios de privacidad desde el diseño: minimización de datos, uso de ubicación agregada por administración zonal, eliminación de identificadores personales, documentación de finalidad académica, control de acceso al repositorio y revisión del tratamiento de datos por el rol Data Governance / DPO.

6. RACI preliminar y timeline

R = Responsable

A = Aprobador

C = Consultado

I = Informado

Actividad	ML Engineer	Data Engineer	Data Analyst	Data Scientist	Data Governance / DPO
Definición del problema	C	C	R	A/R	C
Pregunta analítica	C	C	C	A/R	C
Criterios de éxito técnicos	A/R	C	C	R	C
Criterios de éxito de negocio	C	C	R	A/R	C
Diseño del dataset sintético	C	A/R	C	R	C

Revisión legal y privacidad	I	C	C	C	A/R
Generación de datos ficticios	C	A/R	C	C	I
Pipeline de datos	C	A/R	C	C	I
Limpieza y validación de datos	C	A/R	R	C	C
EDA y visualizaciones	I	C	A/R	C	I
Modelado y evaluación	A/R	C	C	R	I
Interpretabilidad del modelo	R	C	C	A/R	C
Documentación final	R	R	R	R	R
Presentación ejecutiva	R	R	R	R	R

Timeline de 4 semanas

Semana	Actividades principales	Entregables
Semana 1	Definición del problema, stakeholder, pregunta analítica, criterios de éxito, roles, RACI y diseño conceptual del dataset	Acta de constitución del proyecto
Semana 2	Generación del dataset sintético, creación del repositorio, diccionario de datos y pipeline inicial	Dataset CSV, script de generación, diccionario de datos y README
Semana 3	Limpieza, validación, EDA, visualizaciones y definición final de variables para modelado	Notebook de EDA, gráficos principales y reporte preliminar
Semana 4	Modelado, evaluación, interpretación, métrica de negocio, model card y presentación final	Modelo comparado, métricas, dashboard o visualizaciones,

model card y presentación
ejecutiva